


Technical Report — ffni_mediation (Step 2)

日期：2026-08-26 執行，2026-09-01 撰寫 研究：studies/ffni_mediation 資料：results/ffni_mediation/，每條件 40 場，共 80 場 程式版本：commit 0067e63（數字皆可重現；§11.9 的探索性中介是例外——可重算但 倉庫中沒有對應腳本，§12 亦未列出指令）

本報告記錄 Step 2 的完整技術細節：每個假設的估計式、公式、對應的程式路徑、以及實際結果。設計決策的來龍去脈記在 docs/design-log.md §13–§29，本報告只在必要時引用。

1. 研究目標

檢驗一條被廣泛假設但從未被實證檢驗的因果鏈：



Sheng, Andrews & van Vugt (2026, *J. Applied Psychology* 111(6), 768–801) 開發並驗證了 Fundamental Follower Needs Inventory (FFNI)，並在 p.795 明確指出：先前顯示群體衝突提高 支配型領導偏好的研究「假設了追隨者需求的中介角色，卻沒有實證檢驗它——很可能是因為缺乏 經過驗證的測量工具」。

本研究提供該論文所缺的三個條件：

論文		本研究
情境	觀察（相關研究）	操弄（隨機分派到兩個情境）
需求	兩個時點，相隔一週，中間無事件（Sample E）	人內前後測，中間夾一個被操弄的事件
結果	認知／知覺評分	行為（實際投票）

1.1 四個層次

情境與投票之間的黑箱被拆成三個可測的層次，七個假設分別掛在這條鏈的不同段落上。

層次	問什麼	指名誰	工具
需求 (Need)	我想從領導者身上得到什麼	不指名任何人	ffni
原型 (Prototype)	「領導者」這個類別該是什麼樣	明確排除在場的人	leader_ideal
評價 (Evaluation)	這個具體的人當我的領導者會多有效	剛剛一起開會的某人	effectiveness
背書 (Endorsement)	我選誰當領導者	從房間裡選一個	投票

評價與背書的差別是設計上的：評價是絕對的（每個人都可以拿高分），背書是零和的（只能選一個）。

1.2 七個假設

	陳述	測在哪一層
H1	協作情境下，聲望型獲得的同儕票數多於支配型	背書
H2	威脅情境下，支配型獲得的同儕票數多於聲望型	背書
交互作用	威脅情境的「支配-聲望」票數差，大於協作情境的同一差距	背書
H3	威脅相對於協作，提高 protection 需求（人內前後測）。只有 protection ——論文 p.795 把 intergroup conflict 對到 protection，把 status 對到經濟不平等與性別比	需求
H4	認知層：每個需求預測 Table 13 給它顯著增量的那些原型維度（protection → strength；status → tyranny/masculinity/well-groomed；vision、expertise、fairness → 聲望側維度）。 affiliation 刻意沒有條目，見下	需求 → 原型
H5	評價層：論文對六個需求全部都有預測。成立的是 affiliation、vision、expertise、fairness，以及 protection → Safety ；不成立的是 protection → Authoritarianism 與 status 的三條（這裡的 null 是預期結果）	需求 → 評價
H6	protection 需求中介「情境 → 支配型背書」的效果	需求承載情境到背書
H7	威脅強化 protection → 評價層的支配側連結（論文 p.789 的待答問題，原文是 protection–authoritarianism，而 authoritarianism 是 Table 3 的效標）。「縮小兩層落差」那半是本研究自己的延伸，論文沒問過	情境調節上述

三件要先講清楚的事：

交互作用才是對應理論宣稱的檢定，不是 H2。「威脅使偏好轉向支配型」是一個關於變化的宣稱。H1 與 H2 各自顯著並不等於兩者之間有差異，只有交互作用直接檢定那個差距（§6.2）。§8 的檢定力模擬也顯示交互作用比單一條件更有力，因為協作條件往反方向錨定。

H5 的支配側預期是 null，但那個 null 有明確範圍。論文 Table 3 的 protection → **Safety** 是 .20***（強烈成立），protection → **Authoritarianism** 才是 -.01（不成立）；status 的三條（Narcissism、Authoritarianism、Dominance）全部不成立。所以「想要被保護」與「認為以安全為導向的領導有效」是成立的，與「認為威權領導有效」才不成立——分類與聯想是一個歷程，實質評價是另一個。

本研究以一個被觀察者、一題評分代表「對支配型的有效性」，把 Safety 與 Authoritarianism 壓成同一個數字，因此複製到的是一個被合併過的構念的 null（§11.7）。即便如此，null 是預期結果而非失敗——這也是 §5.6 為什麼必須用增量而非雙變量相關：一個不可能失敗的檢定無法複製任何 null。

affiliation 在 H4 缺席是刻意的，在 H5 則是最強的一條。論文 Table 13（原型層）給 affiliation 的 ΔR^2 在全部十一個維度上都是 .00 或 .01、無一顯著，儘管它的雙變量相關高達 .54——那正是雙變量算法看不見的混淆，所以 predicts 沒有它的條目（§23），它只作為控制變項留在迴歸裡。但論文 Table 3（評價層）給它的是 Benevolence .31*** 與 Team-building .46***，是十三條裡最強的兩條。同一個需求在兩層的地位完全不同，這本身就是四層架構要分開測的理由。

H4 是正對照。它不是本研究發明的假設，是論文已發表的正面結果（Study 5, Sample B, Table 13）。它在設計裡的職責是回答「我們的測量在這批 agent 上能不能重現已知的關聯」，而其結果決定其餘結果能推論到多

遠 (§11.1) 。

H6 是主軸。 論文明言這條中介「被假設但從未被實證檢驗」 (p.795)，本研究存在的理由 就是去做那件事。

2. 實驗設計

2.1 母體

36 個 LLM persona，由 `tools/pair_bank.py` 從 3,645 筆的人格庫 (`personas_output.json`) 決定性地產生，職業限制在 `hospital` 設定 (emergency room nurse / pharmacist / hospital administrator / social worker) 。

組	n	每場抽樣	說明
P (Prestige)	6	1	聲望型候選人
D (Dominance)	6	1	支配型候選人， <code>pair_with: "P"</code>
N (Neutral)	24	3	中立者，唯一的受試者與選民

配對構造： P_i 與 D_i 由同一筆人格庫資料產生，因此 Big Five、職業、年齡層、父母身分完全相同，唯一差異是 style block。這消除了人格與職業的混淆 (design-log §3)。`pair_bank.py:163-171` 有斷言比對 P 組與 D 組的 OCEAN、職業、年齡層、父母身分的 **排序後多重集合**，任何破壞組間平衡的修改都會在產生階段失敗，而不是在 1,600 次 API 呼叫之後。注意它擋的是組間平衡，**不是逐一索引的配對**——後者由建構迴圈保證，置換 哪一列餵給哪個 D 索引仍會通過該斷言。

操弄的載體 (persona spec 裡實際帶有的差異)：

- `style.influence`：D 是「Claims influence by taking control of the room...」，P 是「Earns influence by being worth listening to...」
- `personality.traits`：各 6 條行為描述 (D 例：「treats a challenge as something to be shut down, not examined」)
- `speech_examples`：各 4 句 (D 例：「We're doing it this way. Next.」)

`leadership_style` 標籤與 `style.register` 已於 §17 移除——前者是 demand characteristic (TinyTroupe 把整個 persona dict 逐字放進 system prompt)，後者是關於 規格本身的 meta 語言。

2.2 抽樣

`src/pipeline.py:31-49`，`BalancedSampler`：

```
佇列為空 → 用種子化 RNG 產生 0..size-1 的隨機排列
take(n) → 依序取出 n 個；跨越循環邊界時，若抽到已在本場的 index，
          把它推回新循環的尾端，換下一個
```

- **平衡性**：每個 id 在下一輪重複之前必定各出場一次。24 個中立者、每場抽 3，40 場後每人恰好出場 5 次。
- **條件對齊**：sampler 以 `study.sampler_seed` 種子化，因此 run i 在兩個條件抽到 **同一組 cast**。

- **配對組**：D 不獨立抽樣，而是取用 P 的 index (`compose_run` 的 `pair_with` 分支)，所以 P_i 與 D_i 必定同場出現。

跨循環的重複抽樣曾是一個必然當機的 bug (8 人池抽 3, run 3 必掛)，修正記於 §21。

2.3 條件

兩個條件共用 `persona`、`cast` 抽樣與投票題目，只有情境文字不同。`test_core.py` 釘住 `ffni_mediation` 與 `pd_matched` 的情境與 `friction` 文字逐字相同。

- **collaborative**：單位連續兩季未達病安與週轉目標，被授權自行診斷並提出一項變革，48 小時內決定。
- **threat**：醫院整併，兩個重疊單位只保留一個，48 小時內須提出保留本單位的理由，否則由上級決定且會有人失去職位。

兩條件都有 48 小時期限（早期版本只有威脅條件有，那會把威脅與時間壓力混淆，§13 修正）。

3. 執行流程

`src/pipeline.py:80-200`，`run_condition`。一場 run 的順序：

1. baseline 量表	在 fork 上施測	ffni (22題) + leader_ideal (45題)，各 3 次呼叫
2. 討論	3 rounds × 5 人	15 次呼叫，發言順序每輪重洗
3. post 量表	各自從討論後狀態分支出獨立 fork	
	ffni	3 次
	leader_ideal	3 次
	effectiveness	3 人 × 2 候選人 = 6 次
4. 投票	在原始 agent 上	5 次呼叫
		每場 38 次

Fork 機制 (`src/discussion.py:99-135`)。量表施測必須不改變之後要投票的 agent，否則一份 22 題「你想從領導者身上得到什麼」的量表本身就是強烈的 prime。實作：

```
saved = {attr: getattr(person, attr) for attr in _LIVE_WIRING if
hasattr(person, attr)}
for attr in saved: setattr(person, attr, None if attr == "environment" else
[])
try: cloned = copy.deepcopy(person)
finally: for attr, value in saved.items(): setattr(person, attr, value)
```

先拆除 live wiring (`environment`、`_accessible_agents` 等) 再複製，因為 `TinyWorld` 持有 `_thread.RLock`，帶著它的 agent 無法被 `deepcopy`。這是 §21 記錄的資料污染 bug 的修正：原本的實作是先 `deepcopy` 再清欄位，並以 `except Exception: return person` 吞掉失敗，導致每一份 post 量表都寫進了正要投票的那個 agent。現在複製失敗會直接拋出。

`run_discussion` 結束時拆除 `TinyWorld` 並從 `TinyWorld.all_environments` 移除，避免每場累積一個未回收的 `world`。

模型設定 (`config.ini`)：

```
DISCUSSION_MODEL = gpt-4.1      DISCUSSION_TEMPERATURE = 0.7    MAX_TOKENS = 6000
VOTE_MODEL        = gpt-4.1      VOTE_TEMPERATURE      = 0.2    MAX_TOKENS = 3000
SURVEY_MODEL      = gpt-4.1      SURVEY_TEMPERATURE    = 0      MAX_TOKENS = 4500
RUNS = 40         ROUNDS = 3
```

`SURVEY_TEMPERATURE = 0` 的依據見 §7.2。`DISCUSSION_MODEL` 必須是 `gpt-4.1`：`gpt-4o-mini` 上的支配型 `persona` 完全不 `claim` 領導 (`claim` 率 0.00 vs 0.17)，自變項等於沒有被操弄 (§22)。

成本：80 場 × 38 次 ≈ 3,040 次呼叫，6.5 小時，約 27 美金。

4. 測量工具與計分

4.1 三份工具

key	題數	about	量尺	施測時機	誰作答
<code>ffni</code>	22 (6 分量表)	self	1–7	baseline, post	N
<code>leader_ideal</code>	45 (10 維度)	prototype	1–10	baseline, post	N
<code>effectiveness</code>	1 (每個目標)	each_candidate	1–7	post	N

- `ffni`**：Sheng et al. 原始 22 題逐字重現 (Table 5, p.779；2026-09-07 逐題核對，修正 4 處縮寫與 1 處 `toward/towards`)。授權標示 CC BY-NC-ND 4.0 取自預印本，**published 版全文查無此授權**，各頁均為 APA 全權保留——視為未經查證，但不得改寫 仍是安全的讀法。六個分量表：`protection`(4)、`affiliation`(4)、`status`(4)、`vision`(3)、`expertise`(3)、`fairness`(4)。
- `leader_ideal`**：ILT 的重建，而且是與論文所用工具差距很大的重建。論文用 Offermann & Coats (2018) 的 46 題加 `femininity` 與 `ethics` 共 51 題。收集本研究資料時該工具不可得，因此以 Offermann, Kennedy & Wirtz (1994) 的八因素版 (經 Bhatia et al. 2022 附錄轉載，該附錄列出 40 個特質而其正文稱 41，且措辭未經原文核對) 加上論文註 13 的 `femininity` 與 `ethics` 題目重建。

2026-09-07 取得 2018 原文後的逐題比對：本研究施測的 45 個特質中，有 17 個不存在於論文使用的工具裡；共有的 28 個裡有三個歸屬不同——**`bold`** 屬 `charisma`、**`attractive`** 屬 `masculinity`、**`clever`** 屬 `creativity`。這不是「題數較少的同一份量表」，而是不同的工具。正確的 51 題已建於 `instruments/leader_ideal_2018.json` (尚未接上，接上需重跑 原型層)。後果見 §9 與 `design log §31 C3`。

- `effectiveness`**：問句與量尺取自論文，逐字；不同的只有被評的對象，而那是刻意的。

論文 (Study 5, Sample E, p.785) 的指導語是：「Please answer to what extent you perceive these leadership **descriptions** as effective **if these individuals were your own leaders**... (1 = not at all effective as a leader, 7 = extremely effective as a leader)」。本研究用同一個問句、同一組錨點、同一個 1–7，只把 **these leadership descriptions / these individuals** 換成 **this person**：

Think about how this person behaved in the meeting you just had. Please answer to what extent you perceive this person as effective if they were your own leader.

關鍵的理解：論文的效標就是這個問句與這個量尺，不是一份 57 題的量表。那 57 題是 **刺激材料**——12 份已發表的領導風格量表 (Cheng et al. 2004/2014 ; Wang & Howell 2010 ; Bai et al. 2020 ; Hu et al. 2025 ; Back et al. 2013, 清單見論文附錄 p.801) 改寫成假想 領導者的描述，每份量表的 4–6 段描述評分平均成一個「該風格的有效性」分數。把同一個 問句用在不同的刺激上，是在用他們的測量，不是自己發明一個。

本研究的刺激是**受試者剛觀察三輪的具體某人**，這正是 **study.json** 宣稱的第五個缺口（論文的受試者從未觀察過任何人）。每位中立者對每位**候選人**評一次（\$21 起不再評其他 中立者——那 6 次呼叫沒有任何分析讀取）。

代價是信度，而它不是零。Cronbach's α 確實算不出來（單題）。但每一場有 3 位中立者 評同一位被評者的同一場表現，這給出更適合「被觀察對象」的係數：**評分者間信度 ICC(1,1) = .72、ICC(1,3) = .89** (160 個「場次 × 被評者」單元、480 個評分，**analysis.rater_agreement, run.py report** 會印)。 α 問的是「不同說法是否一致」，ICC 問的是「不同觀察者看同一個表現是否一致」，後者才是這裡的問題。

4.2 題目呈現

src/discussion.py:391-397。整份電池在一次 **API 呼叫**內施測，題目順序隨機化：

```
order = random.Random(f"{instrument.key}:\n{participant.persona_id}").sample(items, len(items))
```

順序以「**受試者 × 工具**」為單位固定，不是每次施測重抽。FFNI 的驗證程序要求題目 隨機呈現，且跨受試者的位置偏誤必須被打散；但同一個人在前後測拿到不同順序，會把「換個順序就答不一樣」直接混進前後差異——而前後差異正是 H3 的依變項與 H6 的中介變項。此修正使所有雜訊地板約減半（\$7.3）。

4.3 計分

src/instrument.py:112-126：

```
subscale_score(s) = mean{ r_i : i ∈ items(s), r_i 在量尺範圍內且非 null }
```

缺失值永不插補。超出量尺或模型漏答的題目記為 **null** 並標記，不以中點取代——解析失敗必須讀作缺失資料，而非虛假的中庸作答。整份分量表無可用作答時記為 **NaN**。

effectiveness 為 **about=each_candidate**，其 **ratings()** 回傳 {評分者：{目標：該目標各分量表平均}} (**src/run_record.py:84-92**)。

5. 統計原語

全部實作於 `src/stats.py`，不依賴 `scipy` 以外的套件（`scipy` 僅用於 `t` 分布尾機率）。所有函數丟棄 NaN 而非插補。

5.1 平均與標準差

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$$

僅計非 NaN 的觀察值；樣本標準差在 $n < 2$ 時回傳 0。

5.2 OLS 斜率與相關

`slope(x, y)`， $n < 3$ 或任一邊無變異時回傳 NaN：

$$S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y}), \quad S_{xx} = \sum_i (x_i - \bar{x})^2, \quad S_{yy} = \sum_i (y_i - \bar{y})^2$$

$$b = \frac{S_{xy}}{S_{xx}} \quad r = \frac{S_{xy}}{\sqrt{S_{xx} S_{yy}}}$$

5.3 單尾配對 `t` 檢定

`paired_ttest_onesided(a, b)`，檢定 $\text{mean}(a) > \text{mean}(b)$ ：

$$d_i = a_i - b_i, \quad t = \frac{\bar{d}}{\sqrt{s_d^2/n}}, \quad s_d^2 = \frac{\sum_i (d_i - \bar{d})^2}{n-1}$$

$$p = P(T_{n-1} > t)$$

尾機率由 `scipy.stats.t.sf` 計算。

配對是因為兩組在同一場 `run` 內同時被觀察，`run` 是自然的配對單位。

5.4 Welch 單尾檢定（交互作用用）

`tools/interaction_test.py`：

$$SE = \sqrt{\frac{s_a^2}{n_a} + \frac{s_b^2}{n_b}} \quad t = \frac{\bar{a} - \bar{b}}{SE}$$

$$\nu = \frac{\left(\frac{s_a^2}{n_a} + \frac{s_b^2}{n_b}\right)^2}{\frac{(s_a^2/n_a)^2}{n_a-1} + \frac{(s_b^2/n_b)^2}{n_b-1}} \quad p = 1 - \Phi(t)$$

p 以常態近似 t 分布的尾機率； ν 遠大於 30 時足夠。

用 Welch 而非配對，是保守的選擇：兩個條件的 `run i` 確實抽到同一組 `cast` (§2.2，實測 40/40 場成員完全相同)，但討論、量表作答與投票都是獨立產生的，配對能買到的變異縮減有限，而 Welch 不需要假設兩組變異數相等。

5.5 Cronbach's α

$$\alpha = \frac{k}{k - 1} \left(1 - \frac{\sum_{i=1}^k s_i^2}{s_{\text{total}}^2} \right)$$

k = 題數， s^2_i = 第 i 題的變異數， s^2_{total} = 總分的變異數。整列有任何缺失即剔除（listwise），受試者少於 3 或題數少於 2 時回傳 NaN。

5.6 偏迴歸係數與 ΔR^2

`partial_betas(X, y)`，這是 H4/H5/H7 的核心：

步驟 1： listwise 刪除任何含 NaN 的列。

步驟 2： 標準化每一欄，標準化後不需要截距，係數即為標準化 β ：

$$x_{ij}^* = \frac{x_{ij} - \bar{x}_j}{s_{x_j}} \qquad y_i^* = \frac{y_i - \bar{y}}{s_y}$$

步驟 3： 最小平方配適全模型（`numpy.linalg.lstsq`），並計算模型 R^2 ：

$$\hat{\beta} = \arg \min_{\beta} \| \mathbf{y}^* - \mathbf{X}^* \beta \|^2 \qquad R_{\text{full}}^2 = 1 - \frac{(\mathbf{y}^* - \mathbf{X}^* \hat{\beta})^\top (\mathbf{y}^* - \mathbf{X}^* \hat{\beta})}{\mathbf{y}^{*\top} \mathbf{y}^*}$$

步驟 4： 對每個預測變項 j ，重新配適不含 j 的模型，取 R^2 的落差：

$$\Delta R_j^2 = R_{\text{full}}^2 - R_{(-j)}^2$$

為什麼必須用增量而非雙變量相關。論文 Table 8 顯示六個需求彼此相關 $r = .60-.72$ 。論文 Table 13 對每個原型維度同時報兩欄，以 Strength 為例：

預測變項	雙變量 r	ΔR^2
protection	.38***	.03**
affiliation	.29***	.00
status	.29***	.01
vision	.32***	.00
expertise	.26***	.00
fairness	.26***	.00

六個雙變量相關全部 $p < .001$ ，只有增量能分離出 protection。H4 是關於 **specificity** 的主張（protection 應特別地連到支配側），若用雙變量算，H4 為真與為假會給出相同的結果型態——該檢定不可能失敗，因而不提供任何資訊。此缺陷於 §23 修正，H5 與 H7 同時修正。

註： ΔR^2 是**唯一變異**，共線性會壓縮它。論文自己的顯著增量落在 .01-.06，而同一批 β 是 .19-.32。把 .03 讀作「效果很小」會連同論文的結果一起否定。

5.7 Bootstrap 信賴區間

所有區間皆為 **percentile bootstrap**，重抽單位是 **run**：

對 $k = 1, \dots, B$ ($B = 1000$)：對每個條件，從其 40 場中抽後放回抽出 40 場，在重抽樣本上重跑整個估計式得到 $\hat{\theta}^{(k)}$ 。區間為

$$CI_{95} = [\hat{\theta}^{([0.025B])}, \hat{\theta}^{([0.975B])}]$$

其中 $\hat{\theta}^{(1)} \leq \dots \leq \hat{\theta}^{(B)}$ 為排序後的重抽估計值。

為什麼重抽 run 而非受試者：同一場的 3 個中立者觀看同一段討論，不是獨立觀察。把他們當成 3 筆獨立資料會低估不確定性。模擬顯示忽略此聚類使偽陽性率上升約 2 個百分點 (ICC 由 0 至 .25 時，12% → 14%)——該組數字是在**未置中**的估計式上量的，其中 12% 的底是條件混淆而非聚類。\$26 起 `summarize_mediation` 與 `summarize_layer_moderation` 都改為重抽 run。

5.8 評分者間信度 ICC

`icc_one_way(cells)`。用於 `about=each_candidate` 的工具——那種工具每份只有一題，算不出 Cronbach's α ，但每一場有 k 位受試者評同一個被評者的同一場表現，因此有另一種信度可算。

一個單元是一個（場次 × 被評者），內含 k 個評分。設共 n 個單元：

$$MS_B = \frac{k \sum_{j=1}^n (\bar{x}_j - \bar{x})^2}{n - 1} \quad MS_W = \frac{\sum_{j=1}^n \sum_{i=1}^k (x_{ij} - \bar{x}_j)^2}{n(k - 1)}$$

$\bar{x}_j$ 是第 j 個單元的平均， $\bar{x}$ 是總平均。 MS_B 是**被評者之間的變異**（訊號）， MS_W 是**同一被評者、不同評分者之間的變異**（分歧）。

$$ICC(1, 1) = \frac{MS_B - MS_W}{MS_B + (k - 1) MS_W} \quad ICC(1, k) = \frac{MS_B - MS_W}{MS_B}$$

- **ICC(1,1)** 是單一評分者的信度，**ICC(1,k)** 是 k 人平均後的信度。後者較高，因為個別評分者的隨機偏誤被平均掉了（與 α 隨題數上升同一個機制）。本研究的分析用三人平均，所以 **ICC(1,3)** 才是實際使用的那個量的信度。
- 值域是 $[-\frac{1}{k-1}, 1]$ ，**不是 0 到 1**。 $k = 3$ 時下界為 -0.5，出現在評分者的分歧大於被評者之間的差異時；負值實務上當 0 讀。
- 單元數少於 3、每單元少於 2 人、或 $MS_B = 0$ （被評者之間毫無差異）時回傳 NaN，而非捏造係數。單元大小不一致時取眾數寬度，其餘捨棄。

這是單向隨機效果模型（one-way random effects），對應 Shrout & Fleiss (1979) 的 **ICC(1,1)** 與 **ICC(1,k)**：評分者不固定跨單元——每一場的三位中立者是從 24 人池抽出的不同組合，所以評分者不是可交叉的因子。

實測值 (`analysis.rater_agreement`, `run.py report` 印出)：160 個單元、每單元 3 位評分者、480 個評分， $MS_B = 2.021$ 、 $MS_W = 0.229$ ，**ICC(1,1) = .723**、**ICC(1,3) = .887**。

6. 七個假設：估計式與結果

對應總表：七個假設出自何處，公式是否相同

論文頁碼為期刊頁碼 (`docs/2027-27008-001.pdf` 的 PDF 頁碼 = 期刊頁碼 - 768 + 3)。

	出處	論文的估計式	本研究的估計式	相同？
H1 / H2	非本論文，出自雙路徑文獻	無。論文完全沒有行為結果變項	每場票數的單尾配對 t 檢定	不適用
交互作用	非本論文	無	Welch 單尾檢定 比較兩條件的 $D - P$ 差距	不適用
H3	論文未做，p.795 列為未來方向	無。五個研究皆為自陳與相關設計，從未操弄情境	人內變化量的組間差，bootstrap 區間	不適用
H4	論文的正面結果：Study 5, Sample B, Table 13, p.789–791, $N = 261$	階層多元迴歸 + relative weights analysis (Tonidandel & LeBreton 2011, 2015)。報告 r 、 b 、 SE 、 β 、 ΔR^2 、 RW 、 RW CI、 $RW\%$	標準化偏迴歸 β 與 ΔR^2 (§5.6)	ΔR^2 相同；未做 relative weights；結果變項的聚合方式不同，見下
H5	論文的結果（支配側 null）：Study 5, Sample E, Table 3, p.773, $N = 367$	線性迴歸 Model 1（僅該需求）與 Model 2（控制其餘五個需求），另附 SEM	標準化偏迴歸 β (§5.6)	與 Model 2 相同；效標本身差異很大，見下
H6	論文明言未檢驗，p.795	無	路徑乘積 $a \times b$ + percentile bootstrap (重抽 run)	不適用（無可對照者）
H7	論文列為待答問題，p.789	無	兩條件各自估計後相減，bootstrap 區間	不適用

四處出處的原文：

- **H1 / H2** — 雙路徑模型 (Cheng et al. 2013 ; Henrich & Gil-White 2001) 與威脅效果 (Kakkar & Sivanathan 2017 ; Laustsen & Petersen 2017 ; Spisak et al. 2012)。本論文 p.795 僅引述為背景。
- **H3** — p.795：「Experimental vignette studies offer a useful method for manipulating contextual cues... intergroup conflict may heighten the FFN for protection」。
- **H6** — p.795：「these studies often assume yet do not empirically test the mediating role of follower needs—likely due to a lack of validated measures」。
- **H7** — p.789：「would intergroup conflict situations (e.g., trade wars, organizational crises) strengthen the FFN protection—authoritarianism link?」

七個假設中只有 **H4** 與 **H5** 在論文裡有對應的實證結果，而它們正是本研究的兩個對照：**H4** 為陽性對照（論文有效果），**H5** 支配側為陰性對照（論文為 null）。其餘五個假設論文 或未做（**H3**、**H6**）、或不屬於本論文（**H1**、**H2**、交互作用）、或僅列為待答問題（**H7**）。

H4 的公式異同（細節）

相同的部分：兩者都是「六個需求同時進入模型，讀該需求相對於其餘五個的增量」。論文的 ΔR^2 就是本研究 §5.6 的 $\Delta R_j^2 = R_{\text{full}}^2 - R_{(-j)}^2$ 。

論文採用增量而非雙變量的理由，其正文自己說明了：需求之間高度相關，Study 5 的討論寫「Despite strong correlations among these needs (r ranged from .60 to .72; see Table 8), hierarchical regression confirmed their incremental contributions」。Table 8 (p.783) 的完整相關矩陣範圍更寬，且該引句只涵蓋部分需求與部分樣本；全表最低達 .08 (Sample E T2 的 status–fairness) 。

三個不同的部分：

- 1. **結果變項的聚合方式。**論文對 **11 個 ILT 維度各自配適一個迴歸** (Table 13 有 11 個 criterion 區塊)。本研究把 **predicts** 映射到的維度**先平均成一個複合分數**再配適，每個需求一個迴歸。因此本研究的 **status** 是 tyranny、masculinity、attractiveness 的平均，而論文是三個分開報告。這使本研究無法看出某個需求只在其中一個維度上有效果，§9.2 的逐維度分解即是為了補回這一點。
- 2. **未做 relative weights analysis。**論文同時報 Johnson 相對權重及其 bootstrap 區間；本研究只用 ΔR^2 ，因為它已足以回答假設，而相對權重是為一個沒有分析會讀取的數字增加機制。
- 3. **不確定性的來源。**論文以迴歸的解析標準誤與 relative weights 的 bootstrap (10,000 次，重抽受試者) 報告；本研究以重抽 **run** 的 percentile bootstrap (§5.7)，因為同一場的三位受試者不獨立。

工具亦不同：論文用 Offermann & Coats (2018) 的 51 題 (46 題正式量表 + femininity 2 題

- ethics 3 題)，10 點量尺， α 為 .76–.92；本研究用 45 題的重建版 (§4.1、§11.5)，同為 10 點量尺。

H5 的公式異同 (細節)

相同的部分：論文 Table 3 的 **Model 2** 明確定義為「linear regression models control for the other five follower needs」，這與本研究 §5.6 的偏迴歸 β 是同一個估計式。論文正文亦強調「These relationships remained significant even after controlling for all other FFNs」。本研究的支配側 null 因此是與 Model 2 對照，而非與 Model 1。

兩個不同的部分：

- 1. **刺激材料的性質完全不同** (效標問句本身相同，見 design log §30)。論文讓受試者評 **12 份量表、57 題**改寫成的領導者描述，每份量表的 4–6 題平均成一個分數，Table 3 因 Authoritarianism 出現兩次而有 13 列。支配側是 Authoritarianism、Narcissism、Dominance 三份分開的量表；聲望側是 Benevolence、Team-building、Vision communication、High-expectation、Competence、Intellectual stimulation、Moral character、Virtue，**另有 Safety**——而 Safety 正是 **protection** 強烈成立的那一欄 (.43***/.20***)。沒有任何受試者觀察過任何人。本研究是一個被觀察的具體對象、被評一次。因此本研究的「對支配型的有效性」把論文分開的三份支配側量表壓成一個數字，也把 Safety 與 Authoritarianism 的區別壓掉了。
- 2. **時間間隔。**論文 Sample E 在 Time 1 施測 FFNI，一週後的 Time 2 施測有效性；本研究兩者在同一場會議後相隔數分鐘。

論文支配側 null 的原始數字 (Table 3，Model 1 / Model 2)：

需求 → 風格	Model 1 β	Model 2 β	
Protection → Authoritarianism	-.02	-.01	ns
Status → Narcissism	.04	.03	ns

需求 → 風格	Model 1 β	Model 2 β	
Status → Authoritarianism	-.05	-.02	ns
Status → Dominance	-.12	-.05	ns

對照本研究：protection → 支配型有效性 $\hat{\beta} = -0.002$ ，CI $[-0.139, +0.132]$ 。

注意 Protection → Safety 在論文是 .43* / .20***（強烈成立）。**論文的支配側 null 專指 Authoritarianism；「想要被保護」與「認為以安全為導向的領導有效」是成立的，與「認為威權領導有效」才是不成立的。本研究的單題效標無法區分這兩者，這是 \$11 未列出的一個效度限制，於此補記。

6.0 選民限制

`summarize_contrast` (src/analysis.py:82-143) 只計入非候選組的選票：

```
voters = tuple(k for k in study.groups if k not in (a, b)) or None
```

P 與 D 是被比較的候選人，讓他們在自己的競賽中投票等於把對手的選票放進依變項。cast 為 5 時那是 5 票中的 2 票。因此選民僅為 3 位中立者，每場票數上限為 3。兩位候選人互投的票另外記錄於 `candidate_votes` 但不計入檢定。

6.1 H1 / H2 — 投票

估計式：每場計算兩組各自獲得的中立者票數，做單尾配對 t 檢定。

$$\text{per-run}_i = (v_A(i), v_B(i)), \quad i = 1, \dots, 40 \quad H_0: \mathbb{E}[v_A - v_B] \leq 0$$

其中 $v_G(i)$ 是第 i 場中立者投給組 G 的票數，以 §5.3 的單尾配對 t 檢定。

程式：`summarize_contrast → group_metrics(record, group, voters=('N',))`

結果：

條件	contrast	平均票數	t	p	勝場
collaborative	P > D	P 1.650 (sd 1.167) vs D 0.900 (sd 1.105)	2.199	.0170	25/40
threat	D > P	D 1.575 (sd 1.318) vs P 1.100 (sd 1.128)	1.277	.1047	23/40

H1 成立，H2 單獨不成立。

附帶指標（同一檢定套用於其他 DV）：threat 條件的 speech rate D .992 vs P .958（ $p = .052$ ）；words per turn D 33.5 vs P 41.4——**注意此檢定方向固定為 `contrast[0] > contrast[1]`，而 P 在兩條件都比 D 話多，因此該行的 p 值無意義，應讀原始平均數（§8 已記錄此為報表假象）。**

6.2 交互作用 — 主要檢定

這是唯一真正對應「威脅造成轉變」這個理論宣稱的檢定。兩個條件各自顯著並不等於兩者之間有差異。

估計式：

$$g_i = v_D(i) - v_P(i)$$

$$H_0 : \mathbb{E}[g \mid \text{threat}] \leq \mathbb{E}[g \mid \text{collab}]$$

以 §5.4 的 Welch 單尾檢定比較兩個條件的 g 。

程式：`tools/interaction_test.py` `ffni_mediation`

結果：

```
threat          mean(D-P) = +0.47    sd = 2.35    n = 40
collaborative   mean(D-P) = -0.75    sd = 2.16    n = 40
Welch t = 2.427, df ≈ 77.4, 單尾 p = .00762    → 成立
```

行為效果複製。檢定力模擬 (§4 舊表) 早已顯示交互作用比單一條件更有力，因為協作條件 往反方向錨定，把待檢定的差距拉開；H2 單獨落在 .105 是預期內的。

6.3 H3 — 情境是否推動需求

估計式：人內變化的組間差。

$$M_p = \text{score}_{\text{post}}(p) - \text{score}_{\text{baseline}}(p)$$

$$a = \frac{1}{|T|} \sum_{p \in T} M_p - \frac{1}{|C|} \sum_{p \in C} M_p$$

T 與 C 分別為威脅與協作條件的受試者集合；信賴區間以重抽 run 的 bootstrap 求得。

程式：`summarize_layer_moderation` 的 `induced` 欄位 (`src/analysis.py`)

結果 (1–7 量尺，每條件 120 位受試者)：

need	協作	威脅	差	95% CI	
protection	-0.748	-0.438	+0.310	[0.125, 0.496]	排除 0
affiliation	-0.050	-0.152	-0.102	[-0.229, 0.029]	
status	-0.371	-0.373	-0.002	[-0.102, 0.092]	
vision	+0.233	+0.125	-0.108	[-0.244, 0.019]	
expertise	-0.169	-0.258	-0.089	[-0.203, 0.033]	
fairness	+0.106	+0.077	-0.029	[-0.115, 0.050]	

H3 成立。 威脅推動的正是論文對這種情境預測的那一個需求，其餘五個的區間皆含 0。

注意 status 的區間含 0 不是缺憾。 論文 p.795 把 status 對應到經濟不平等與性別比，把 intergroup conflict 對應到 protection，並另外問「攻擊性戰爭是否提升 status 需求，而 防禦性戰爭啟動 protection 需求」。本研究的威脅是單位可能不保的組織整併——是群體間衝突，而且是防禦性的。**因此 protection 動、status 不動，正是論文的預測本身，而非部分達成。** (H3 原本寫成「提高 protection 與 status」，那個 status 沒有論文依據，見 design log §33。)

必須注意的細節： $M_p < 0$ 在兩個條件皆成立——protection 都在下降，威脅只是讓它跌得較少。組間比較成立，但這不是「威脅使需求絕對上升」。六個需求在合併資料上的人內變化（240 人）全部顯著非零，最大是 protection $-0.59 [-0.69, -0.49]$ ——**討論本身** 使多數需求下降，而情境只調節了幅度。這也證明量表對討論有反應性：measure-check 顯示什麼都不發生時 protection 的變化 SD 僅 0.40。

6.4 H4 — 認知層（需求 → 領導者原型）

這是論文的正面結果（Study 5, Sample B, Table 13, p.789–791, $N = 261$ ），本研究將其設為**正對照**。估計式與論文的異同見本節開頭的對應總表。

預測映射（`leader_ideal.json` 的 `predicts`，取自論文 Table 13 的顯著 ΔR^2 ）：

```
protection → strength
status      → tyranny, masculinity, attractiveness    (attractiveness 是
1994 年的名稱，2018 改名 well-groomed)
vision      → sensitivity, dedication, charisma
expertise   → sensitivity, charisma, intelligence
fairness    → dedication, intelligence, ethics
affiliation → （無條目）
```

affiliation 的條目已於 §23 移除：論文 Table 13 顯示它在全部 11 個維度上 ΔR^2 皆為 .00 或 .01 且無一顯著，而雙變量相關高達 .54——它正是舊估計式看不見的那種混淆。它仍留在迴歸中作為控制變項。

估計式（兩種讀法）：

(a) 水準值（論文問法的）：

$$y_p = \frac{1}{|D_m|} \sum_{d \in D_m} \text{prototype}_d(p)$$

$$\mathbf{X} = [m_1 \ m_2 \ \dots \ m_6] \quad (240 \times 6), \quad \hat{\beta}_m, \Delta R_m^2 \text{ 由 } \mathbf{X}, \mathbf{y} \text{ 依 §5.6 求得}$$

六個需求 $m_1 \dots m_6$ 全部進入模型，讀該需求自己那一欄的 $\hat{\beta}$ 。

(b) 人內變化（論文的資料問不出來的）：

$$\Delta m_p = m_{\text{post}}(p) - m_{\text{base}}(p) \quad \Delta y_p = \frac{1}{|D_m|} \sum_{d \in D_m} [\text{proto}_{d,\text{post}}(p) - \text{proto}_{d,\text{base}}(p)]$$

$$\hat{\beta}_m \text{ 由 } \Delta \mathbf{X}, \Delta \mathbf{y} \text{ 依 §5.6 求得}$$

(b) 之所以可能，是因為 §24 為 `leader_ideal` 加了 baseline 施測——baseline fork 不帶逐字稿，是整個設計中最便宜的呼叫。

程式：`summarize_layer_moderation` 的 `cognition` 與 `cognition_induced`

結果（討論後資料，pooled，條件內各自置中）：

need	水準值 β	95% CI	ΔR^2	變化量 β	95% CI
protection	-0.072	[-0.195, +0.046]	.0050	+0.048	[-0.089, +0.193]

need	水準值 β	95% CI	ΔR^2	變化量 β	95% CI
status	-0.160	[-0.277, -0.051]	.0222	+0.048	[-0.083, +0.175]
vision	+0.068	[-0.042, +0.170]	.0041	+0.015	[-0.099, +0.135]
expertise	+0.123	[-0.020, +0.243]	.0131	+0.093	[-0.037, +0.221]
fairness	+0.031	[-0.042, +0.105]	.0008	+0.025	[-0.073, +0.110]

H4 不成立：protection 兩種讀法的區間皆含 0。status 顯著但方向相反。

與論文條件對齊的補充分析 (§28)。論文是在冷測條件下以水準值測量，而上表用的是 討論後分數。既然 `leader_ideal` 已有 baseline，最接近論文的分析是「前測需求 → 前測原型」：

need	β	95% CI	論文方向	
expertise	+0.23	[0.12, 0.34]	+	複製
vision	+0.13	[0.03, 0.23]	+	複製
status	-0.03	[-0.14, 0.10]	+	null
protection	-0.16	[-0.29, -0.02]	+	顯著反向
fairness	-0.20	[-0.31, -0.11]	+	顯著反向

反向的穩健性經 8 個不同 bootstrap 種子（各 2000 次抽樣）驗證，8/8 皆排除 0，上界穩定在 -0.02 至 -0.03。

五條中三條排除 0，因此這不是量表在吐雜訊，而是有結構的失敗：聲望側複製、支配側反向。診斷見 §9。

6.5 H5 — 評價層（需求 → 對具體某人的有效性評分）

論文的 Study 5 (Sample E, Table 3, p.773, $N = 367$) 以線性迴歸檢定，其 Model 2 控制其餘五個需求，並明言「These relationships remained significant even after controlling for all other FFNs」。其支配側是 **null**：「the FFNs for protection and status failed to predict perceived effectiveness of dominance-based leadership styles」。因此本研究的支配側預期也是 **null**，那是複製成功。效標性質的重大差異見本節開頭的 對應總表。

估計式：與 H4(a) 同一個設計矩陣，只換結果變項。

$$\text{eff}_A(p) = \frac{1}{|A_p|} \sum_{t \in A_p} r(p \rightarrow t)$$

$$\text{eff}_B(p) = \frac{1}{|B_p|} \sum_{t \in B_p} r(p \rightarrow t)$$

A_p 、 B_p 分別是該場的支配型與聲望型候選人， $r(p \rightarrow t)$ 是 p 給 t 的有效性評分。以與 H4(a) 同一個 **X** 配適：

$\hat{\beta}_m^{(A)}$ 由 **X**, eff_A 依 §5.6 求得

注意：每個評分組各配適一次迴歸（結果變項對所有需求是同一欄），而非每個需求各配適一次——這才是論文的模型形狀。

程式：`summarize_layer_moderation` 的 `evaluation_a / evaluation_b`

結果：

need	→ 支配型 β	95% CI	→ 聲望型 β	95% CI
protection	-0.002	[-0.139, +0.132]	+0.053	[-0.068, +0.171]
affiliation	-0.190	[-0.318, -0.070]	+0.151	[+0.013, +0.303]
status	+0.120	[-0.011, +0.248]	+0.010	[-0.129, +0.121]
vision	+0.033	[-0.102, +0.168]	+0.068	[-0.042, +0.169]
expertise	+0.005	[-0.120, +0.146]	+0.113	[-0.024, +0.275]
fairness	+0.105	[-0.041, +0.206]	-0.088	[-0.175, +0.017]

- 支配側 null → 複製成功 (protection -0.002, status 區間含 0)
- 聲望側：論文的 vision / expertise / fairness 三條皆未複製 (區間全含 0)。唯一顯著的是 affiliation (→ 聲望型 +0.151、→ 支配型 -0.190)，方向與論文報告的 benevolence / team-building 大致相符。

6.6 H6 — 中介

這是論文明言從未被檢驗的那一條 (p.795)，也是本研究的主軸。論文沒有可對照的估計式，因此下列設計選擇皆為本研究自訂。

估計式 (`summarize_mediation`, `src/analysis.py:337-495`)：

單位為每場的每位中立者， $40 \times 3 = 120$ 列／條件。

$$M_p = m_{\text{post}}(p) - m_{\text{base}}(p) \quad Y_p = 1[\text{vote}(p) = D]$$

path a — 誘發需求組間差：

$$a = \frac{1}{|T|} \sum_{p \in T} M_p - \frac{1}{|C|} \sum_{p \in C} M_p$$

path b — 條件內各自置中後合併，取 OLS 斜率：

$$\tilde{M}_p = M_p - \bar{M}_{c(p)}, \quad b = \frac{\sum_p (\tilde{M}_p - \bar{\tilde{M}})(Y_p - \bar{Y})}{\sum_p (\tilde{M}_p - \bar{\tilde{M}})^2}$$

其中 $c(p)$ 是 p 所屬的條件， $\bar{M}_c$ 是該條件的組內平均。

間接效果：

$$\widehat{ab} = a \times b$$

$$\text{CI}_{95} = [Q_{0.025}, Q_{0.975}] \text{ of } \left\{ \widehat{ab}^{(1)}, \dots, \widehat{ab}^{(B)} \right\}, \quad B = 1000$$

$\widehat{ab}^{(k)}$ 為第 k 次重抽 run 後重算的間接效果；判準為 CI_{95} 排除 0。

三個刻意的設計選擇：

1. 中介變項是變化量而非水準值 (§18)。論文的 null 是關於慢性的、特質式的需求；本研究主張的是情境誘發的狀態，水準值會把兩者混在一起。論文自己也把這個歧義列為限制：「it remains unclear

whether perceived threats **increase** protection needs or whether certain individuals are **chronically inclined** toward this need」。

2. 結果變項是受試者自己的那一票，不是全組票數。這是論文點名「從未測過」的行為 後果；同時使 H6 與 H5 不會壓在同一個係數上卻做相反預測。
3. path b 在條件內置中。不置中的話，威脅同時抬高誘發需求與直接抬高背書（後者即 H2），使合併斜率在需求毫無作用時仍為正。模擬顯示不置中的偽陽性率為 13%（5 人 30 場）至 20%（10 人 20 場），且不隨 n 縮小——只有 CI 縮小，所以場次 越多越糟。置中後回到約 7%。

結果：

path a	= +0.3104	威脅確實推高了誘發的保護需求
path b	= -0.0055	但誘發需求完全預測不到那一票
indirect	= -0.00171	95% CI [-0.02702, +0.02413]
bootstrap draws	= 1000	n = 120／條件，40 場／條件
supported	= False	

H6 不成立。

此 null 的資訊量，以及它的上限。由 $\widehat{ab} = a \times b$ 且 $a = 0.31$ 反推 path b 的隱含區間：

$$b \in \left[\frac{-0.02702}{0.3104}, \frac{+0.02413}{0.3104} \right] \approx [-0.087, +0.078]$$

這個區間排除中效果，不排除小效果，理由有兩層，兩層都會把宣稱往下拉。

第一層：模擬的 b_{vote} 與估計出的 path b 不是同一個量。`layer_power.py` 的 $P(\text{vote} = D) = 0.5 + b_{\text{vote}} \cdot M^{\text{true}}$ 乘的是真實誘發變化，而估計式迴歸的是觀測變化 $M^{\text{obs}} = M^{\text{true}} + \eta$ 。兩者差一個衰減（§11.2 的 ρ_{MM} ）。用模擬器自己的產生器實測：

模擬設定	估計式實際看到的 path b
$b_{\text{vote}} = 0.10$ (小)	+0.023 — 落在區間內
$b_{\text{vote}} = 0.25$ (中)	+0.142 — 落在區間外

第二層：上面的除法把 a 當成已知。 a 自己的 95% CI 是 [0.125, 0.496]。取下界時 隱含區間變成 $[-0.216, +0.193]$ ，連中效果都框不住。

因此正確的陳述是：這筆資料能排除中等強度的中介，不能排除微小的中介。這仍比「沒看到」強——中效果在此 n 下的偵測率是 95%，若它存在應該會出現——但遠不到「排除除極小效果之外的一切」。

退化情況的處理 (§27)：若某條路徑無變異（例如所有受試者投票一致），path b 無法 配適、bootstrap 無樣本可抽。此時報表印「NOT ESTIMABLE — 0 usable bootstrap draws. A path is degenerate, not null.」而非「no mediation evidence」。判準亦由「兩端同號」改為「區間排除 0」——前者會讓退化區間 [0, 0] 通過。

6.7 H7 — 威脅的調節作用

H7 有兩個部分。

(a) 威脅是否強化「誘發保護需求 → 支配型背書」：

$$b_c = \text{slope}(\{\tilde{M}_p\}_{p \in c}, \{Y_p\}_{p \in c})$$

$$\Delta b = b_{\text{threat}} - b_{\text{collab}}$$

結果：協作 -0.005、威脅 -0.006、差 **-0.002**，CI **[-0.127, +0.155]** → 乾淨的 null。

(b) 威脅是否縮小認知層與評價層的落差：

$$\text{gap}_c = \hat{\beta}_m^{\text{cog}}(c) - \hat{\beta}_m^{(A)}(c)$$

$$\Delta \text{gap} = \text{gap}_{\text{threat}} - \text{gap}_{\text{collab}}$$

兩個 $\hat{\beta}$ 都在該條件內單獨配適，且皆為標準化係數，因此可直接相減。

need	協作 gap	威脅 gap	差	95% CI	
protection	+0.130	-0.337	-0.467	[-0.822, -0.159]	排除 0
status	-0.107	-0.442	-0.335	[-0.705, +0.028]	
vision	+0.071	-0.008	-0.079	[-0.459, +0.250]	
expertise	-0.002	+0.134	+0.136	[-0.235, +0.511]	
fairness	+0.094	-0.168	-0.261	[-0.522, +0.160]	

protection 的區間排除 0，但方向與假設相反。H7 預測威脅使兩層收斂（落差趨近 0）；實際上落差由 +0.13 變為 -0.34，絕對值變大且穿過零點。

拆解此差異的來源：

	協作	威脅	差	95% CI	
認知層	+0.052	-0.251	-0.303	[-0.520, -0.085]	排除 0
評價層	-0.078	+0.086	+0.164	[-0.083, +0.442]	

驅動落差的是認知層：威脅使 protection → 原型的關聯**更負**。兩個差相減（-0.303 - 0.164 = -0.467）與表中的落差差一致。點估計取自 checkpoint 的確定性重算；早期版本此處誤植 bootstrap 平均（-0.305 / +0.178），使算術不閉合。

本研究不將此列為結論，理由：(i) 五個需求做了五次檢定， $\alpha = .05$ 下期望 0.25 個假陽性；(ii) 合併後兩層皆為 null，此為「差的差」，容易是雜訊；(iii) 每條件僅 120 人 40 場，per-condition 估計本身不穩；(iv) 方向與假設相反，故 H7 無論如何不成立。

H7 兩部分皆不成立。

7. 測量效度驗證

`run.py measure-check ffni_mediation`。在支付正式研究之前，對每個可在無會議情況下作答的工具（`about` 為 self 或 prototype）施測**兩次**，中間不發生任何事。36 個 persona × 2 個工具 × 2 次 = 144 次呼叫，約 8 分鐘、2 美金。

`effectiveness` 無法以此方式檢驗——它詢問「你剛開完的那場會」，而此處沒有會議。但這不代表它沒有**信度**：它的評分者間信度由 `analysis.rater_agreement` 從正式資料算出（ICC(1,1) = .72、ICC(1,3) = .89），印在 `run.py report` 裡，見 §4.1。

7.1 四個閘門

src/render.py:199-236 :

閘門	判準	意義
分量表區辨	SD(各分量表平均) > 0.30	工具是否區分不同構念
直線作答	整份給同一數字的比例 < 0.30	agent 是否放棄作答
內部一致性	每個被分析讀取的分量表 $\alpha > 0.60$	同一分量表的題目是否測同一件事
重測穩定	平均 test-retest $r > 0.40$	相同條件下能否重現自己的答案

內部一致性閘門為 **per-subscale** (§23)。原本是十個分量表取平均，而 **protection** 只對應一個原型維度 **strength** (2 題) ——平均會讓 **tyranny** (10 題) 把死掉的 **strength** 撐過關，使 H4 與 H6 的主線建立在雜訊上。被把關的集合是 **predicts** 值的聯集，因此無人讀取的維度 (femininity) 不會擋下研究，而新加入映射的維度會自動被納入。

重測閘門的上限已移除 (§26)。原本是 $0.40 < r < 0.85$ ，上限用於捕捉「agent 太穩定，情境推不動」。但在題序固定且 temperature 為 0 之後，兩次施測是幾乎相同的 prompt，test-retest 量到的是「相同 prompt 是否給相同答案」——那是量測應有的性質。FFNI 隨即以 0.89「不合格」，那不是關於 FFNI 的發現。情境能否推動分數，是由 H3 的 path a 在真的發生了事情的資料上回答，不是由「什麼都不發生地問兩次」回答。

7.2 三次執行的結果

平均 test-retest			
	FFNI	leader_ideal	判決
temperature 0.2，題序每次重洗	.645	.346	ILT 不合格
temperature 0，題序每次重洗	.650	.467	合格
temperature 0，題序依人固定	.894	.758	合格

失敗的方向與 §12 的預期相反：不是 agent 太穩定，而是**重現不了自己的答案**。α 全程良好 (.73–.99)，45 題也無人直線作答——單次作答內部連貫，兩次之間對不上。

7.3 雜訊來源的分解

test-retest 幾乎完全由「人間 SD ÷ 雜訊 SD」決定 (temperature 0.2 時)：

	人間 SD	雜訊 SD	比值	retest
affiliation	1.36	0.63	2.15	.90
sensitivity	1.06	0.70	1.52	.83
protection	0.79	1.01	0.78	.21
strength	0.49	0.67	0.74	.23

因此並非「agent 對領導者的看法完全一致而無個體變異」——人間 SD 是實在的。問題是雜訊與訊號等大。

temperature 只解決約三分之一：最差的原型量表接近翻倍（strength .23→.46，dedication .27→.56，intelligence .18→.41），FFNI 幾乎不動（.645→.650）。

題序是主因。固定題序後（第三列），所有雜訊地板約減半：

	修正前	修正後
protection 雜訊 SD	1.01	0.40
protection retest	.26	.83
strength retest	.46	.81
masculinity retest	.01	.63

這是本次工作對統計效力影響最大的單一改動。

7.4 正式研究所用設定下的完整測量指標

SURVEY_TEMPERATURE = 0，題序依人固定，36 個 persona：

FFNI (1–7)

分量表	前測平均	人間 SD	Δ平均	Δ SD	α	retest
protection	5.58	0.64	+0.08	0.40	.93	.83
affiliation	5.58	1.33	+0.02	0.38	.99	.96
status	2.44	0.72	+0.02	0.25	.93	.95
vision	5.78	0.77	+0.06	0.30	.97	.92
expertise	5.62	0.96	+0.17	0.39	.97	.91
fairness	6.66	0.81	+0.10	0.50	.99	.79

leader_ideal (1–10)

維度	題數	前測平均	人間 SD	Δ SD	α	retest
strength	2	7.31	0.56	0.36	.87	.81
tyranny	10	2.72	0.96	0.39	.92	.91
masculinity	2	2.53	0.88	0.70	.94	.63
attractiveness	4	4.10	0.62	0.64	.92	.58
sensitivity	8	6.92	1.11	0.46	.99	.91
dedication	4	8.69	0.48	0.27	.87	.84
charisma	5	7.68	0.50	0.34	.89	.76

維度	題數	前測平均	人間 SD	Δ SD	α	retest
intelligence	5	8.09	0.39	0.31	.82	.70
femininity	2	2.35	0.82	0.63	.97	.64
ethics	3	8.86	0.92	0.55	.99	.80

仍未解決的問題：重測閘門仍是取平均。`masculinity`(.63) 與 `attractiveness`(.58) 即使修正後仍偏低，而 `status` 的複合分數正是對這兩者加上 `tyranny` 取平均——三個出口有兩個信度偏低。若把重測也改為 per-subscale 把關，需先決定門檻。

8. 檢定力模擬

`tools/layer_power.py`。此前只有投票的檢定力被計算過（`tools/power_sim.py`），H3–H7 是不同的估計量、不同的資料結構，從未被評估。

方法：造合成資料，其中效果量已知，用真正的分析函數（`summarize_layer_moderation`、`summarize_mediation`）去跑，計算「該估計式自己的 bootstrap 區間排除 0」的比例。不用公式，因為分析包含公式處理不了的東西：分層資料、兩個估計相乘、bootstrap 區間。

資料產生模型（每場、每位受試者）：

$$u_{\text{room}} \sim \mathcal{N}(0, 0.3^2)$$
$$\ell_p \sim \mathcal{U}(2, 6)$$
$$M_p^{\text{true}} = \text{lift} + u_{\text{room}} + \varepsilon_p, \quad \varepsilon_p \sim \mathcal{N}(0, \sigma_{\text{true}}^2)$$
$$M_p^{\text{obs}} = M_p^{\text{true}} + \eta_p, \quad \eta_p \sim \mathcal{N}(0, \sigma_{\text{noise}}^2)$$
$$\Delta_{\text{proto}_p} = \beta_{\text{proto}} M_p^{\text{true}} + \mathcal{N}(0, 1)$$
$$\text{eff}_p = 4 + \beta_{\text{eff}} M_p^{\text{true}} + \mathcal{N}(0, 1)$$
$$P(\text{vote}_p = D) = \text{clip}(0.5 + b_{\text{vote}} M_p^{\text{true}}, 0, 1)$$

該場討論對所有人的共同影響
該人的基準需求水準
情境真正造成的位移
量表報告的位移

參數分離 (§26 修正)：`sd_true` 是情境真正推動各人的差異，`sd_noise` 是量表加上的雜訊，即 `measure-check` 的 Δ SD。兩者方向相反——原型與投票追隨真實變化，而所有估計式只看得到觀測變化，因此雜訊衰減斜率、真實變異支撐檢定力。原本用單一參數 `sd_induced` 同時代表兩者，會使「雜訊地板降低」看起來像「檢定力下降」。

結果 (`sd_noise` = 0.40 為實測值，`sd_true` = 0.5、`beta_proto` = 0.5、`beta_eff` = 0、100 reps、200 draws)：

runs／條件	H3	H4 人內	H5 偽陽性	H6 (b=.10)	H6 (b=.25)
20	92%	65%	13%	20%	—
40	100%	94%	2%	31%	95%
60	100%	97%	4%	44%	100%

`beta_eff` = 0 時 H5 那欄是偽陽性率而非檢定力——論文的 null 是預期結果，重要的是它維持在名目 5% 附近。

樣本數決定：每條件 40 場。

- H3 已飽和。雜訊地板減半使其由 84%（舊參數）升至 100%。
- H5 的偽陽性率在 20 場是 13%，40 場才回到名目。這是「40 場是下限」的真正理由，而該理由與檢定力無關。H5 的支配側是預註的預期 null，而由偽陽性率 13% 的檢定得出的 null 不可解讀。
- H4 人內為 94%。
- H6 是懸崖而非斜坡：小效果時 40 場 31%、60 場 44%（皆不足）；中效果時 40 場已 95%（無需增加）。多花 50% 預算在兩端都無回報。

H6 的命運因此取決於誘發需求對投票的真實效果量，而非預算。

9. H4 失敗的診斷

正對照失敗會限制其他結果能推論多遠，因此需要具體診斷而非籠統歸因。

9.1 排除計分錯誤

顯著反向最明顯的候選原因是反向題未被反轉計分。兩份工具都沒有反向題：FFNI 的四個 protection 題目全為正向敘述（「I wish to have a leader who positions themselves between my group and an outside threat」），`leader_ideal` 全為特質形容詞（strong、bold、domineering），評「多符合領導者」。

9.2 反向有結構，不是雜訊

protection 對十個原型維度分別的偏迴歸係數（前測，六需求模型，240 列）：

維度	β	維度	β
charisma	+0.21	strength	-0.16
ethics	+0.17	masculinity	-0.07
dedication	+0.15	femininity	-0.06
attractiveness	+0.12	tyranny	-0.05
sensitivity	+0.04	intelligence	-0.02

正向側是 charisma、ethics、dedication；負向側是 strength、masculinity、tyranny。這正是聲望側與支配側的分界，且分割乾淨。壞掉的量表回傳雜訊，不會回傳一個沿著理論軸線的連貫反轉。

9.3 「bold」這個詞扛了整個反向

`strength` 只有兩題。分開檢視（24 位中立者的跨場平均分數）：

	strong	bold
protection →	-0.02	-0.29
openness →	+0.39	+0.24
平均分數	7.25	7.11
人間 SD	0.45	0.37

protection 對 "strong" 幾乎無關聯 (−0.02) ，整個反向來自 "bold" (−0.29) 。

一個高保護需求的 persona 是安全取向的，而 "bold (大膽)" 在語義上是冒險。它給 bold 低分不是因為不想強壯的領導者，而是因為「大膽」讀起來像會冒險。

論文的量表在 Strength 維度上有更多題目來稀釋單一詞的語義；本研究的重建只有 2 題，其中 1 題的語義恰好與保護需求對衝。這是量表重建的缺陷 (§19 已記錄此風險) ，不是心理學發現。

9.4 變異範圍嚴重受限

strength	平均 7.18/10	人間 SD 0.39	範圍 6.2 – 8.0
charisma	平均 7.61/10	人間 SD 0.37	範圍 7.0 – 8.2

24 個 persona 全部落在 1.8 分的區間內 (滿分 10) 。所有 agent 都同意領導者該強壯、該有魅力，剩餘變異極小，一個語義偏誤即足以蓋過真實訊號。

9.5 Big Five 在兩端留下相反印記

persona 的需求與原型皆由同一份 Big Five 描述生成：

Big Five	→ protection	→ strength	→ charisma
openness	−0.33	+0.34	+0.10
conscientiousness	+0.23	+0.17	−0.19
extraversion	+0.16	−0.03	+0.58
agreeableness	+0.28	+0.15	+0.22
neuroticism	+0.10	−0.09	−0.29

openness 把兩者往相反方向拉：低開放性 → 想要保護、但覺得領導者不需要 bold。

人層次的 protection ↔ strength 相關為 −0.15 (n = 24) ，與 240 列的偏迴歸係數 −0.16 幾乎相同——確認此反向完全來自 24 個 persona 之間的既有差異，與討論或情境無關。

9.6 診斷結論與解釋排序

按證據強度：

- 1. 量表重建的語義缺陷 (§9.3) 。直接證據，且可修：Strength 維度僅 2 題，其中 "bold" 與保護需求語義對衝。
- 2. 變異範圍受限 (§9.4) 。所有原型維度都擠在高分區間，訊號空間小。
- 3. persona 生成方式 (§9.5) 。需求與原型出自同一份人格描述，其間的關聯是模型 自身的一致性邏輯，無理由重現人類的個體差異結構。

此排序修正了 §28 的初始判斷，該節將「這些是 LLM persona 而非人」列為首要解釋。證據顯示應反過來：反向的直接來源是可修的量表缺陷。至於「LLM persona 的需求–原型 結構天生不同於人類」這個更大的主張，目前僅 fairness (−0.20) 尚無此類簡單解釋，證據強度弱於 §28 所述。

10. 結果總表

假設	內容	論文做過？	結果	關鍵數字
H1	協作：P > D	無（雙路徑文獻）	成立	p = .017
H2	威脅：D > P	無（同上）	單獨不成立	p = .105
—	交互作用	無	成立	Welch p = .0076
H3	威脅提高保護需求	無：p.795 列為未來方向	成立，且僅此一個需求	+0.310 [0.125, 0.496]
H4	需求 → 原型	有：Table 13, p.789	不成立；前測顯著反向	-0.16 [-0.29, -0.02]
H5	需求 → 有效性（支配側）	有：Table 3, p.773	null，複製成功	-0.002 [-0.139, +0.132]
H5	需求 → 有效性（聲望側）	有：Table 3, p.773	vision/expertise/fairness 未複製； affiliation 複製	affiliation +0.151 [+0.013, +0.303]
H6	中介	無：p.795 明言未檢驗	不成立	a×b = -0.0017 [-0.027, +0.024]
H7a	威脅強化 need → 票	無：p.789 列為待答	不成立（null）	-0.002 [-0.127, +0.155]
H7b	威脅縮小兩層落差	無	不成立（方向相反）	-0.467 [-0.822, -0.159]

七個假設中，論文做過的只有 H4 與 H5 兩個，而它們正是本研究的兩個對照：H4 為陽性對照、H5 支配側為陰性對照。

11. 效度威脅

11.1 正對照失敗（最嚴重）

H4 是論文的正面結果，本研究做成不成立且前測顯著反向（該反向的成因見 §9，並參見 design log §31 C3——**bold** 在論文實際使用的工具裡屬於 charisma，不屬於 strength）。H5 聲望側論文預測的 vision / expertise / fairness 三條也未複製。

但「論文做過的預期有效果部分全部沒複製」並不成立。**affiliation** 對兩側都複製到了：

	我們	論文 (Table 3, Model 2)
affiliation → 聲望側有效性	+0.151 [+0.013, +0.303]	Benevolence .31***、Team-building .46***
affiliation → 支配側有效性	-0.190 [-0.318, -0.070]	（論文未預測支配側）

那是論文最強的兩條支持性連結，方向一致且區間排除 0。所以正確的說法是：**論文的正面 結果我們複製到一條、沒複製到四條**（H4 的 protection/status、H5 的 vision/expertise/ fairness），而唯一預期為 null 的那條複製成功。

這使 H6 的 null 必須分兩個範圍陳述：

- **關於本模擬**：誘發的保護需求不預測這些 agent 的背書，而且能排除中等強度的中介（\$6.6）。**此宣稱成立，但範圍比先前版本所寫的小**：小效果排除不了。
- **關於人類**：證據力有限。一群重現不出已知關聯（甚至做成反向）的受試者，在一個從未被檢驗的關聯上回報 null，對真實人類母體的推論力薄弱。

行為層結果（交互作用 $p = .0076$ ）不受影響——它不依賴原型層。

11.2 中介變項的測量

protection 的 retest 為 .83（題序修正後的最佳值）， ΔSD 為 0.40。這是整條鏈上最弱的一環。若真實 path b 存在但被衰減，本研究可能低估它。以 $\sigma_{\text{true}} = 0.5$ 、 $\sigma_{\text{noise}} = 0.40$ 估計中介變項的信度：

$$\rho_{MM} = \frac{\sigma_{\text{true}}^2}{\sigma_{\text{true}}^2 + \sigma_{\text{noise}}^2} = \frac{0.25}{0.25 + 0.16} \approx 0.61$$

古典衰減公式下，觀測斜率約為真值的 ρ_{MM} 倍。

11.3 中介變項的測量時點

中介變項在討論之後測量，而投票隨後發生。一個在討論期間升起、於結束前回落的需求，在本設計中不可見。

11.4 房間層次的共同原因

path b 在條件內以 40 場中的 120 位受試者估計。bootstrap 重抽 run，因此區間誠實；但房間層次的共同原因（例如某場的 D 特別強勢，使該場的中立者同時需求上升且投給 D）不會以中介的形式現形，也不會被此設計排除。

11.5 ILT 為重建工具

`leader_ideal` 是 1994 年八因素版加補充題目的重建，非論文所用的 2018 年修訂版（\$19）。已知兩個缺陷：來源附錄列出 40 個特質而其正文稱 41，可能遺漏一個；所有措辭未經 1994 或 2018 原文核對。`strength` 僅 2 題，而 \$9.3 顯示這正是問題所在。

11.6 自變項從未被檢核

沒有任何研究對 P/D 的操弄做過操縱檢核。`pd_matched` 的 `instruments` 是空的，`ffni_mediation` 只有 `ffni`、`leader_ideal`、`effectiveness` 三份，全部問的是需求、原型或對某人的評價，**沒有一份問「你覺得這個人有多支配／多有聲望」**。`design log $13` 的操縱檢核測的是**威脅情境**（位置不安穩、時間緊迫、後果嚴重），不是領導風格，而且它已於 \$13 退場。

`tools/sample_bank.py` 的 `STYLE_BLOCKS` 是為本研究撰寫的，沒有引用任何已發表的操弄材料或量表（本報告亦未宣稱有）。構念定義（Cheng et al. 2013；Henrich & Gil-White 2001）說 dominance 是「透過恐懼與強制」取得影響力，而文字只寫到「讓異議代價高昂」；\$11.6 記錄的投票理由掃描顯示恐懼／強制語言為 0%。

支持操弄有效的唯一證據是**行為的**：支配型 claim 領導權的比率在 **gpt-4.1** 上是 0.17–0.25，聲望型是 0.00（S9 的診斷同一批資料）。那證明兩組行為不同，**不證明**它們是雙路徑模型意義下的支配型與聲望型。

補救最直接的是把 Cheng, Tracy & Henrich 的 Dominance-Prestige Scale 當成 **about: each_candidate** 的操縱檢核，讓中立者在討論後對兩位候選人各評一次。結構與 **effectiveness** 相同，每場多 6 次呼叫。

11.7 §13 的操縱證據早於 deadline 修正

§13 的威脅操縱檢核 (5.38 vs 3.21) 是在 **pd_matched** 的舊協作情境文字下收集的，當時只有威脅條件有 48 小時期限。§2.3 引用該修正時未註明操縱證據位於修正之前。§13 論證該證據仍可轉移；此處記錄的是那個論證尚未被新資料檢驗。

11.8 投票理由與機制的關係

tools/vote_reason_scan.py 對 Step 1 的分析顯示：恐懼／強制語言在投票理由中 **完全不存在**（0%），而果斷／負責的措辭占 84%（D 票）。但該比率在協作條件是 82%，**兩條件幾乎相同**，因此它解釋不了「為什麼威脅造成轉變」。

兩種無法由現有資料區分的解釋：(i) 支配型的行為在威脅情境下**功能上**就是果斷，而被獎勵的是果斷本身；(ii) LLM 投票者系統性地把支配行為的投票重寫成社會上較體面的能力語言——若為真，則投票理由與自陳量表皆非通往機制的可靠窗口，而那是本研究**唯一擁有的**機制資料。

11.9 未預註的探索性發現

以下**不是**預註假設，是在「還有什麼可能」的探索中得出，且在找到它之前檢視了 4 個行為指標，區間未針對此搜尋做校正。**應視為下一個研究的假設，不是本研究的結論。**

以 D 在該場討論的**發言字數佔比**為中介變項，重跑同一個中介估計式：

path a	= +0.0182	威脅使 D 多佔約 1.8 個百分點的發言空間	CI [0.001, 0.037]
path b	= +4.464	發言佔比強烈預測該場投 D 的比例	CI [2.965, 6.109]
indirect	= +0.0814	95% CI [+0.0064, +0.1663]	
總效果	= +0.2250	被中介的比例 36%，CI [6%, 104%]	

（對照：protection 的間接效果為 -0.002，CI [-0.027, +0.024]。）

四項限制：(i) 事後分析；(ii) path a 很弱，下界 0.001；(iii) 被中介比例的區間寬至 104%；(iv) 房間內的因果方向未確立。

此發現與其他所有觀察一致：投票理由 0% 恐懼／84% 果斷、果斷措辭在兩條件幾乎相同（改變的不是理由而是 D 佔了多少地板）、六個需求與十個原型維度全部不承載效果。

12. 重現方式

```
cd /tmp2/b12902056/agent-sim
python3 test_core.py
```

42 項離線檢查

```
# 不呼叫 API，從既有 checkpoint 重算
python3 run.py report ffni_mediation threat
python3 run.py report ffni_mediation collaborative
python3 run.py layers ffni_mediation # H3, H4, H5, H7
python3 run.py mediate ffni_mediation --need protection --group D # H6
python3 tools/interaction_test.py ffni_mediation # 交互作用

# 需呼叫 API
python3 run.py measure-check ffni_mediation # 144 次，約 2 美金
python3 run.py run ffni_mediation threat # 40 場，約 3 小時

# 純 CPU
python3 tools/layer_power.py --reps 100 --runs 20 40 60 --sd-noise 0.4 --sd-true 0.5
python3 tools/power_sim.py # 投票的檢定力
```

results/**/checkpoints/ 與 logs/ 不進版控 (.gitignore)，摘要 JSON 與圖表進版控。重跑同一道 run 指令會跳過已完成的場次，只補缺的——中斷、配額用盡或機器重開皆可續跑。

產生條件的記錄（2026-09-07 起）：每份摘要都帶一個 provenance 區塊，記錄三個模型 與其 temperature、rounds、以及每份量表的指紋。指紋是關鍵的那一項——item id 是位置 編號，所以 leader_ideal 這個名字本身並不指明是哪一版。2026-08-26 以前的摘要沒有這個 區塊，三次 measure-check 仍依賴檔名後綴 (_t0、_fixorder) 與本報告區分。

本報告的原型層數字對應 1994 重建版 (leader_ideal_1994.json，指紋見該檔)。2018 版已於 2026-09-07 接上為 leader_ideal.json，兩版共用 36 個 item id 而其中 28 個 題目不同，因此 RunRecord 會拒絕以其中一版計分另一版收集的作答——對既有 checkpoint 執行 run.py report 會停在 run 1 並指出 attractiveness_*。原型層要更新需重跑。

13. 主要程式路徑索引

功能	位置
CLI	run.py (list / validate / measure-check / run / report / mediate / layers)
設計載入與驗證	src/study.py
量表載入、predicts 驗證、分量表計分	src/instrument.py
抽樣、組場、執行、checkpoint	src/pipeline.py
討論、投票、量表施測、fork、題序	src/discussion.py
checkpoint 的唯一格式知識	src/run_record.py

功能	位置
統計原語	src/stats.py
H1–H7 的估計式	src/analysis.py
報表輸出與閘門判定	src/render.py
交互作用檢定	tools/interaction_test.py
投票檢定力	tools/power_sim.py
層次假設檢定力	tools/layer_power.py
persona 產生	tools/pair_bank.py
投票理由掃描	tools/vote_reason_scan.py